

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO TUẦN 5
MÔN THỰC TẬP CƠ SỞ

**Đề tài: Nghiên cứu, đánh giá và triển khai
mô hình Deep Learning tối ưu cho hệ thống phân loại rác thải**

Giảng viên hướng dẫn:	TS. Kim Ngọc Bách
Sinh viên thực hiện:	Nguyễn Văn Gia Bảo
Mã sinh viên:	B23DCCN079

Hà Nội - 2026

MỤC LỤC

1. Mục tiêu công việc trong tuần	3
2. Nội dung công việc đã thực hiện	3
2.1 Xây dựng và huấn luyện (Fine-tune) mô hình EfficientNet	3
2.2 Đánh giá mô hình	4
3. Kết quả đạt được	4
3.1 Kết quả mô hình EfficientNet sau fine-tune.....	4
3.2 So sánh với mô hình EfficientNet cũ (chỉ train lớp cuối)	5
3.3 Bảng tổng hợp so sánh hiệu năng 3 mô hình (cập nhật)	6
4. Khó khăn gặp phải	6
5. Kế hoạch tuần tiếp theo	7

1. Mục tiêu công việc trong tuần

- Cải thiện độ chính xác của mô hình EfficientNet B0 (đã chọn từ tuần trước) bằng cách áp dụng fine tune toàn bộ thay vì chỉ huấn luyện lớp cuối.
- Sử dụng các kỹ thuật nâng cao: data augmentation mạnh hơn, class weighting, learning rate nhỏ, và tăng số epoch.
- Đánh giá chi tiết kết quả mới, so sánh với mô hình EfficientNet cũ (chỉ train lớp cuối) và các mô hình khác.

2. Nội dung công việc đã thực hiện

2.1 Xây dựng và huấn luyện (Fine-tune) mô hình EfficientNet

Ở tuần trước, mô hình EfficientNet chỉ được huấn luyện ở lớp classifier cuối cùng (đóng băng toàn bộ backbone). Tuần này, tiến hành fine-tune toàn bộ với các cải tiến:

- Mở khóa (unfreeze) toàn bộ backbone: Cho phép cập nhật trọng số của tất cả các lớp trong EfficientNet-B0, giúp mô hình thích nghi tốt hơn với đặc trưng của rác thải (thay vì chỉ dùng đặc trưng từ ImageNet).
- Data augmentation mạnh hơn:
 - RandomResizedCrop (256 $\rightarrow$ 224)
 - RandomHorizontalFlip, RandomRotation(20)
 - ColorJitter (brightness, contrast, saturation, hue)
 - RandomAffine (dịch chuyển nhẹ)
 - RandomErasing (Cutout) với xác suất 0.2
- Class weighting: Tính trọng số cho mỗi lớp dựa trên số lượng mẫu trong tập train (công thức balanced), giúp mô hình chú trọng hơn vào lớp trash (vốn có rất ít ảnh).
- Learning rate:
 - Backbone: 1e-5 (nhỏ hơn rất nhiều so với 1e-3 trước đây để tránh phá hủy trọng số đã học)
 - Lớp classifier mới: 1e-4
 - Sử dụng ReduceLROnPlateau với patience=5, factor=0.5
- Số epoch: Tăng từ 10 lên 40.
- Hàm mất mát: CrossEntropyLoss kết hợp với class weights.

2.2 Đánh giá mô hình

- Sử dụng bộ dữ liệu TrashNet (2527 ảnh), chia train/val/test theo tỷ lệ 70/15/15, đảm bảo phân bố lớp đồng đều.
- Tập test gồm 380 ảnh (giống với tuần trước để so sánh công bằng).
- Tính toán các chỉ số: Accuracy, Precision, Recall, F1-score, Confusion Matrix.


3. Kết quả đạt được

3.1 Kết quả mô hình EfficientNet sau fine-tune

- Test Accuracy: 85.79% (tăng 6.58% so với 79.21% của phiên bản chỉ train lớp cuối)
- Macro F1-score: 0.84 (tăng từ 0.75)

Kết quả chi tiết từng class:

Class	Precision	Recall	F1- score
Cardboard	0.98	0.90	0.94
Glass	0.89	0.84	0.86
Metal	0.72	0.92	0.81
Paper	0.89	0.89	0.89
Plastic	0.98	0.75	0.85
Trash	0.59	0.85	0.69



Hình 1 - Confusion Matrix của EfficientNet sau fine-tune

3.2 So sánh với mô hình EfficientNet cũ (chỉ train lớp cuối)

Chỉ tiêu	EfficientNet (cũ)	EfficientNet (fine-tune)	Thay đổi
Test Accuracy	79.21%	85.79%	+6.58%
Macro F1-score	0.75	0.84	+0.09
Recall của lớp Trash	0.36 (8/22)	0.85 (17/20)	+0.49
Số epoch	10	40	+30
Dung lượng model	~15.6 MB	~15.6 MB	Không đổi

Nhận xét:

- Lớp Trash là cải thiện rõ rệt nhất: recall từ 36% lên 85%. Mô hình bắt đầu nhận dạng đúng rác hỗn hợp, giảm mạnh nhầm lẫn sang Paper và Metal.
- Glass và Metal ít nhầm lẫn hơn: số lượng glass bị đoán thành metal giảm từ 15 xuống 8.

- Plastic có precision rất cao (0.98), nhưng recall còn thấp (0.75) – model vẫn bỏ lỡ một số ảnh plastic, có thể do hình dạng hoặc màu sắc giống với glass/metal.
- Metal có recall rất tốt (0.92) nhưng precision thấp (0.72) – vẫn bị nhầm từ glass và plastic sang metal. Đây là điểm cần cải thiện thêm.

3.3 Bảng tổng hợp so sánh hiệu năng 3 mô hình (cập nhật)

Để có cái nhìn tổng quan và đưa ra quyết định lựa chọn mô hình triển khai thực tế, em đã tổng hợp các tiêu chí đánh giá vào bảng sau:

Tiêu chí	VGG16	ResNet50	EfficientNet	EfficientNet (mới)
Test Accuracy	83.42%	79.47%	79.21%	85.79%
Macro F1-score	0.80	0.75	0.75	0.84
Dung lượng tệp	~512 MB	~90 MB	~15.6 MB	~15.6 MB
Số epoch	10	10	10	40
Thời gian huấn luyện	Rất chậm	Trung bình	Nhanh	Trung bình (~40 phút trên GPU)

Kết luận: Efficient-net sau fine-tune không chỉ vượt trội về dung lượng mà còn đạt độ chính xác cao nhất (85.79%), cao hơn cả VGG16 (83.42%). Như vậy, mô hình EfficientNet với fine-tune hoàn toàn là lựa chọn tối ưu cho bài toán phân loại rác thải.

4. Khó khăn gặp phải

- Thời gian huấn luyện: Fine-tune toàn bộ với 40 epoch mất khoảng 40 phút trên GPU (dù nhanh hơn VGG16 nhiều). Việc chạy lại nhiều lần để thử nghiệm siêu tham số không khả thi do thời gian có hạn.
- Lớp Metal vẫn bị nhầm lẫn: Precision của Metal chỉ đạt 0.72 do glass và plastic có bề mặt bóng, phản chiếu ánh sáng giống kim loại. Cần thêm ảnh đa dạng hoặc sử dụng kỹ thuật ensemble để cải thiện.
- Lớp Plastic còn recall thấp: Mặc dù precision rất cao (0.98), model vẫn bỏ lỡ 25% ảnh plastic. Nguyên nhân có thể do thiếu các mẫu plastic có hình dạng không điển hình (túi nilon, màng bọc...).

5. Kế hoạch tuần tiếp theo

- Tìm hiểu framework Streamlit bằng ngôn ngữ Python để bắt đầu xây dựng giao diện người dùng (Web Application).
- Xây dựng giao diện Web cho phép người dùng tải (upload) ảnh rác thải lên hệ thống và hiển thị kết quả phân tích.
- Tích hợp "bộ não" EfficientNet-B0 đã Fine-tune (đạt 85.79%) vào ứng dụng Streamlit để thực hiện nhận diện theo thời gian thực (Real-time inference).